ISPC
INSTITUTO SUPERIOR POLITÉCNICO CÓRDOBA

Tecnicatura Superior en
Ciencia de Datos e Inteligencia Artificial

TRABAJO PRÁCTICO INTEGRADOR - EJE I
Fundamentos y Procesamiento Digital de la Señal
Evidencia de aprendizaje nº1

Técnicas de Procesamiento del Habla

Estudiantes:
Melania Ligorria
Miguel Rojas
Emilce Robles
Ian Marini

Docente:
Rubén Giudice Bojanich

Dirección General de EDUCACIÓN TÉCNICA Y FORMACIÓN PROFESIONAL
Ministerio de EDUCACIÓN
CÓRDOBA Seguimos haciendo

TRABAJO PRÁCTICO INTEGRADOR - EJE I

Fundamentos y Procesamiento Digital de la Señal

Materia: Procesamiento Digital de Señales de Audio

Duración estimada: 6-8 horas

Modalidad: Grupos

Entrega: Notebook de Google Colab + Informe en PDF

CONSIGNAS GENERALES

Objetivos del Trabajo Práctico:

Al finalizar este TP, deberás ser capaz de:

1. Aplicar correctamente los conceptos de muestreo, cuantización y detección de aliasing
2. Preparar un dataset de audio crudo aplicando técnicas de limpieza y normalización
3. Realizar un análisis exploratorio completo (EDA) utilizando la Transformada de Fourier
4. Extraer conclusiones fundamentadas sobre las características de las señales analizadas
5. Documentar el proceso de manera clara y reproducible

Escenario:

Trabajarás con un **dataset de comandos de voz** que contiene grabaciones de las palabras "sí", "no", "izquierda" y "derecha". Las grabaciones fueron realizadas en condiciones no controladas (diferentes micrófonos, ambientes ruidosos, duraciones variables).

PARTE 1: FUNDAMENTOS TEÓRICOS (20 puntos)

Pregunta 1.1: Muestreo y Teorema de Nyquist (5 puntos)

a) Explica con tus palabras qué es el muestreo y por qué es necesario digitalizar una señal de audio.

El muestreo es el proceso de convertir una señal continua (analógica) en una señal digital tomando valores en intervalos de tiempo regulares. Es decir, una señal analógica tiene infinitos valores en el tiempo, mientras que una computadora solo puede trabajar con valores discretos (separados).

Por eso, para poder almacenar, procesar y analizar audio en una computadora, es necesario transformarlo en una secuencia de muestras digitales.

b) Una señal de voz tiene componentes de frecuencia hasta 4000 Hz.
¿Cuál es la frecuencia de muestreo mínima teórica necesaria?

Según el Teorema de Nyquist, la frecuencia de muestreo debe ser al menos el doble de la frecuencia máxima de la señal.

En este caso:
Frecuencia máxima = 4000 Hz
Frecuencia mínima de muestreo = 8000 Hz

Esta es considerada la “regla de oro” del procesamiento de señales, porque garantiza que la señal pueda reconstruirse correctamente sin perder información.

Si muestreamos a 6000 Hz, ¿qué problema podríamos tener?

Si se muestrea a 6000 Hz, se viola el criterio de Nyquist y aparece el fenómeno de aliasing.

El aliasing ocurre cuando las frecuencias altas de la señal se “mezclan” y se interpretan como frecuencias más bajas. Es decir, el sistema se confunde y reconstruye una señal incorrecta.

Esto genera distorsión, porque la señal digital ya no representa fielmente a la original.

¿Por qué el audio de teléfono usa 8000 Hz?

El audio telefónico utiliza 8000 Hz porque alcanza para transmitir la voz humana de forma entendible.

La mayoría de la información importante del habla está por debajo de los 4000 Hz, por lo que esta frecuencia cumple con Nyquist y permite:

- Buena inteligibilidad
- Menor uso de datos
- Transmisión más eficiente

Es un estándar en telecomunicaciones porque es un equilibrio entre calidad y eficiencia.

c) Investigá: ¿por qué el audio de CD usa 44100 Hz y no 40000 Hz exactamente?

El oído humano puede escuchar frecuencias de hasta aproximadamente 20000 Hz. Entonces, siguiendo Nyquist, se necesitaría al menos 40000 Hz.

Sin embargo, se usa **44100 Hz** para asegurarse de capturar todo el sonido audible sin errores y con buena calidad.

Pregunta 1.2: Cuantización y Resolución (5 puntos)

a) Compará dos grabaciones de la misma señal:

Grabación A: 8 bits de resolución

Grabación B: 16 bits de resolución

Explicá:

¿Cuántos niveles de amplitud tiene cada una?

Una grabación de 8 bits puede representar 256 niveles de amplitud, mientras que una de 16 bits llega a 65536 niveles. Esto se debe a que los niveles se calculan como 2^n, donde *n* es la cantidad de bits. Es decir, cada bit duplica la cantidad de valores posibles, por lo que al aumentar los bits, aumenta exponencialmente la precisión con la que se puede representar la señal.

¿Cuál tendrá mejor calidad y por qué?

La grabación de 16 bits va a tener mejor calidad porque puede representar muchos más niveles de amplitud. Esto hace que la señal sea más fiel al original y que el sonido se escuche más suave y menos escalonado.

¿Qué desventaja tiene la grabación B?

La desventaja es que al tener más información, ocupa más espacio y también puede requerir más procesamiento.

b) Si una señal tiene un rango dinámico de 96 dB, ¿cuántos bits mínimos se necesitan para representarla sin perder información? (Pista: cada bit aporta ~6 dB).

Se divide el rango dinámico (96 dB) por lo que aporta cada bit (6 dB), lo que da 16 bits. Esto indica que con 16 bits alcanza para representar todas las diferencias entre sonidos suaves y fuertes sin perder detalle.

Pregunta 1.3: Aliasing (5 puntos)

a) Describí el fenómeno de aliasing con un ejemplo cotidiano (puede ser el de la rueda de carroza en películas u otro que conozcas).

El aliasing es cuando una señal se “interpreta mal” porque fue muestreada con una frecuencia demasiado baja.

Un ejemplo típico es el de las ruedas en las películas: a veces parece que la rueda gira más lento, se queda quieta o incluso gira para atrás. Eso no es real, es un efecto visual causado porque la cámara “toma muestras” (frames) a cierta velocidad.

Con el audio pasa algo parecido: si muestreamos mal, las frecuencias altas se transforman en otras más bajas que no corresponden. Es como si el sistema “se confundiera” al leer la señal.

b) Matemáticamente:
Señal original: 7000 Hz
Frecuencia de muestreo: 8000 Hz
¿Qué frecuencia "falsa" aparecerá después del muestreo?
Mostrá el cálculo

Primero aplicamos el criterio de Nyquist:
Para evitar aliasing se debe cumplir: Frecuencia de muestreo ≥ 2 × frecuencia de la señal.

Entonces:
2 × 7000 = 14000 Hz ← frecuencia mínima necesaria
Pero se está muestreando a 8000 Hz
Como 8000 < 14000, no se cumple el teorema de Nyquist.

Ahora calculamos la frecuencia de Nyquist del sistema:

Nyquist = 8000 / 2 = 4000 Hz
Como la señal (7000 Hz) es mayor que 4000 Hz, se produce aliasing.

La frecuencia falsa se calcula como: $f_{alias} = |f - fs|$

Entonces: f_alias = |7000 - 8000| = 1000 Hz
Resultado: aparece una frecuencia falsa de 1000 Hz en lugar de 7000 Hz.

c) ¿Cómo se puede prevenir el aliasing? Mencioná al menos dos estrategias.

El aliasing se puede prevenir de las siguientes maneras:

- Aumentando la frecuencia de muestreo: cumpliendo el teorema de Nyquist (al menos el doble de la frecuencia máxima de la señal).
- Aplicando un filtro pasa bajos (anti-aliasing): antes de muestrear, se eliminan las frecuencias altas que no se pueden representar correctamente.

Pregunta 1.4: Dominio del Tiempo vs. Frecuencia (5 puntos)

a) Completá el cuadro comparativo:

Característica	Dominio del Tiempo	Dominio de la Frecuencia
¿Qué muestra?	Muestra cómo cambia la amplitud de la señal en el tiempo	Muestra qué frecuencias componen la señal
Herramienta principal	Forma de onda (waveform)	FFT (Transformada de Fourier)
Ejemplo de uso	Detectar silencios o cortes en el audio	Identificar tonos o frecuencias dominantes

b) Explicá qué es la Transformada de Fourier y por qué es importante en el análisis de audio.

La Transformada de Fourier es una herramienta matemática que permite transformar una señal del dominio del tiempo al dominio de la frecuencia. Es decir, toma una señal que vemos como una onda en el tiempo y la descompone en las frecuencias que la componen.

Se puede entender con una analogía: así como un prisma descompone la luz blanca en distintos colores, la Transformada de Fourier descompone una señal en las distintas frecuencias que la forman.

Es importante en el análisis de audio porque permite entender qué frecuencias están presentes en una señal, lo que es clave para tareas como identificar tonos, analizar timbre o clasificar sonidos.

c) Si ves un espectro con un pico muy alto en 440 Hz y picos más bajos en 880 Hz y 1320 Hz, ¿qué podés concluir sobre la señal?

Si en el espectro aparece un pico muy alto en 440 Hz, esto indica que esa es la frecuencia fundamental de la señal, componente principal.

Los otros picos en 880 Hz y 1320 Hz son múltiplos de 440, por lo tanto son armónicos. Esto significa que la señal no es un tono puro, sino que tiene un timbre más complejo, ya que está formada por varias frecuencias y no solo una.

PARTE 3: ANÁLISIS E INTERPRETACIÓN (20 puntos)

Ejercicio 3.1: Informe Técnico (15 puntos)

Redactar un informe de máximo 3 páginas que incluya:

1. Introducción (2 puntos)

- Objetivo del trabajo
- Descripción del dataset
- Metodología aplicada

El objetivo del presente laboratorio fue analizar señales de audio mediante técnicas de procesamiento digital, abordando el flujo completo desde la obtención de los datos hasta su caracterización mediante features y análisis estadístico.

Para ello, se trabajó con un conjunto de señales de audio. En una primera instancia, se utilizaron señales sintéticas compuestas por cuatro clases (grave, medio, agudo y ruido), diseñadas con rangos de frecuencia controlados. Este enfoque permitió trabajar en un entorno simplificado donde las diferencias entre clases pueden observarse de

manera clara. Asimismo, esta metodología es aplicable al análisis de comandos de voz reales como “sí”, “no”, “izquierda” y “derecha”.

La metodología aplicada incluyó:

- Generación de señales sintéticas con variabilidad controlada.
- Aplicación de un pipeline de preprocesamiento.
- Estandarización de las señales (duración y amplitud).
- Extracción de características (features).
- Análisis exploratorio de datos (EDA).
- Evaluación de separabilidad mediante Análisis de Componentes Principales (PCA).

2. Resultados del Preprocessing (4 puntos)

- Problemas detectados en los datos crudos
- Transformaciones aplicadas y justificación
- Impacto cuantitativo (reducción de duración, normalización, etc.)

Inicialmente, el dataset presentaba ciertas inconsistencias propias de datos no estandarizados:

- Variabilidad en la duración de las señales
- Diferencias en la amplitud entre muestras
- Falta de uniformidad estructural

A diferencia de datasets reales, no se detectó una presencia significativa de silencios, lo cual se evidenció en que el proceso de trimming no generó reducciones relevantes.

Para resolver estas diferencias, se aplicaron las siguientes transformaciones:

- **Normalización de amplitud**, para unificar la escala de las señales.
- **Padding y cropping**, para estandarizar la duración a 2 segundos.
- **Remuestreo a 22050 Hz**, asegurando consistencia en la frecuencia de muestreo.

- **Trimming**, incluido en el pipeline aunque sin impacto significativo en este dataset.

Desde el punto de vista cuantitativo, se logró:

- Estandarizar la duración de todas las señales a **2.0 segundos** (desde un rango original de 1.5 a 2.5 segundos).
- Normalizar la amplitud máxima a **1.0 en todas las muestras.**
- El trimming no produjo reducciones significativas (≈0%), lo cual es consistente con la ausencia de silencios en el dataset sintético.

Como resultado, se obtuvo un dataset homogéneo, adecuado para análisis comparativo y extracción de características sin sesgos derivados de diferencias estructurales.

3. Análisis Exploratorio (6 puntos)

- Características distintivas de cada clase
- Features más discriminativas identificadas
- Correlaciones importantes detectadas
- Visualización de la separabilidad (PCA)

El análisis exploratorio permitió identificar características distintivas entre las clases:

- Las señales **graves** concentran su energía en bajas frecuencias.
- Las señales **medias** se ubican en rangos intermedios.
- Las señales **agudas** presentan mayor contenido en altas frecuencias.
- La clase **ruido** muestra un espectro amplio y sin estructura definida.

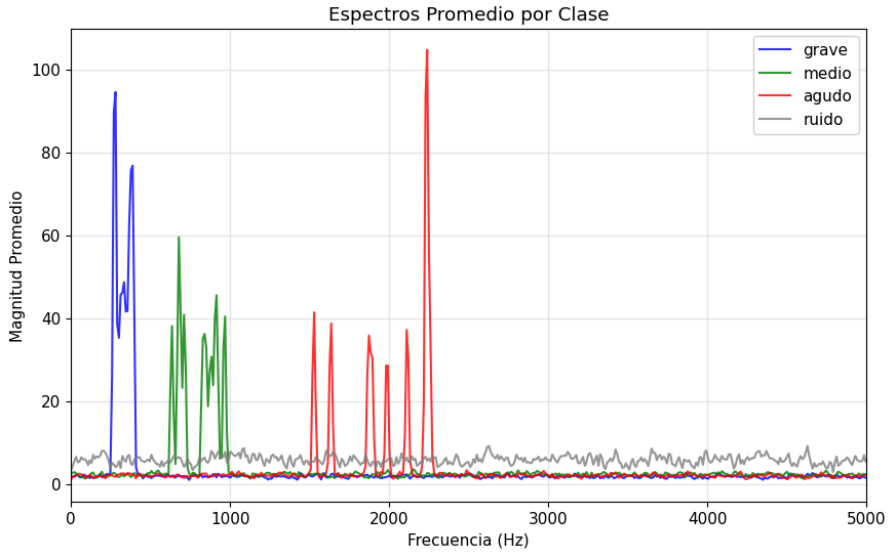

Espectros promedio por clase (grave, medio, agudo y ruido)

Features más discriminativas

Las características más relevantes para la diferenciación fueron:

- **Spectral centroid**, que indica el centro de masa del espectro.
- **Spectral rolloff**, que refleja la distribución acumulada de energía.
- **Zero Crossing Rate (ZCR)**, relacionado con la variabilidad temporal.
- **Spectral flatness**, especialmente útil para distinguir señales de ruido de señales tonales.

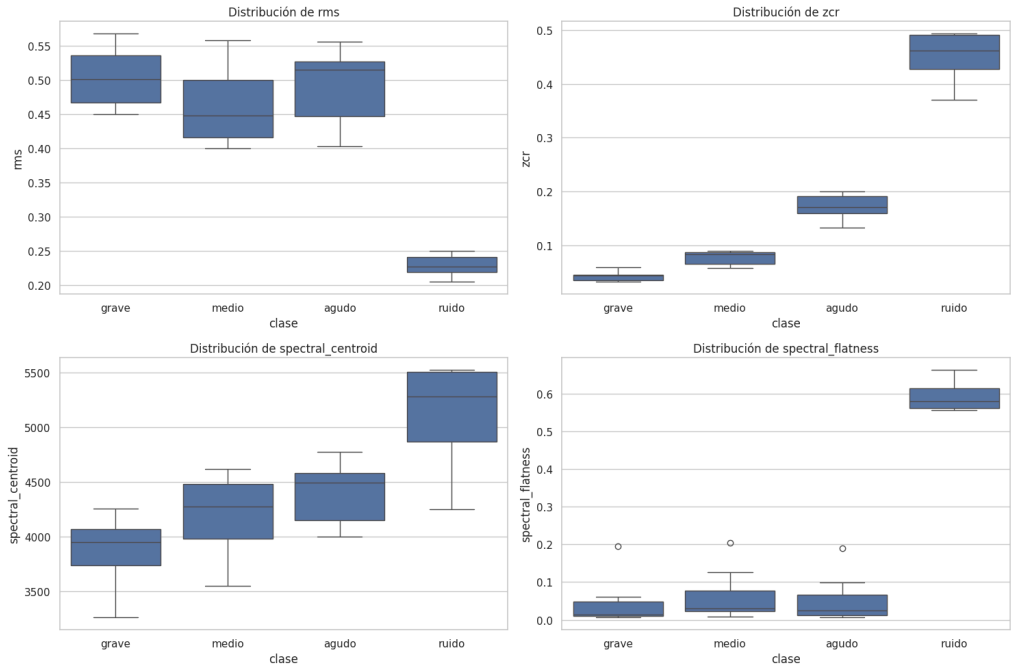

Distribución de features (boxplots)

Correlaciones importantes

El análisis de correlación evidenció relaciones significativas entre variables:

- Alta correlación entre **ZCR y spectral flatness.**
- Relación inversa entre **RMS y spectral flatness.**

Esto indica la existencia de redundancia entre algunas features, lo cual podría optimizarse mediante selección de variables en etapas posteriores.

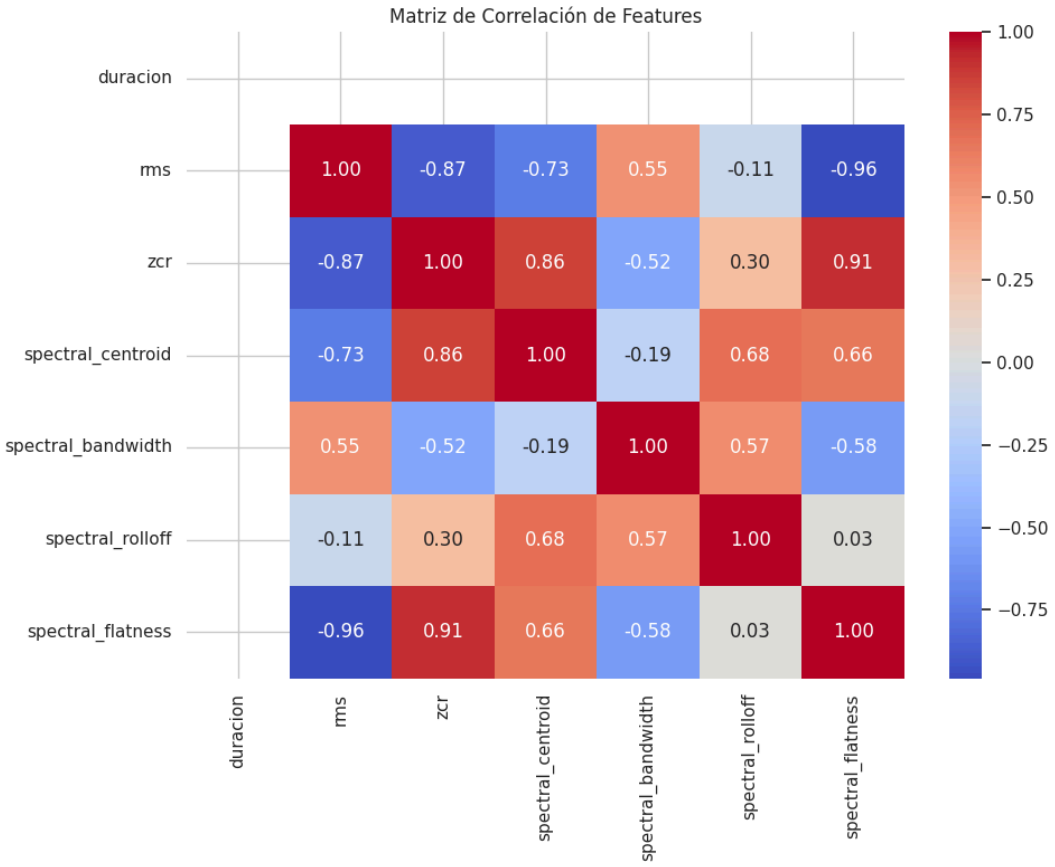

Matriz de correlación

Separabilidad mediante PCA

El análisis de componentes principales permitió reducir la dimensionalidad del dataset conservando aproximadamente **93.89% de la varianza total** con solo dos componentes.

En la proyección bidimensional:

- La clase **ruido** se separa claramente del resto.
- Las clases **grave, medio y agudo** presentan cierto solapamiento.

Este comportamiento se explica por la baja complejidad espectral del dataset, ya que las señales están basadas principalmente en ondas senoidales con diferencias limitadas en su estructura.

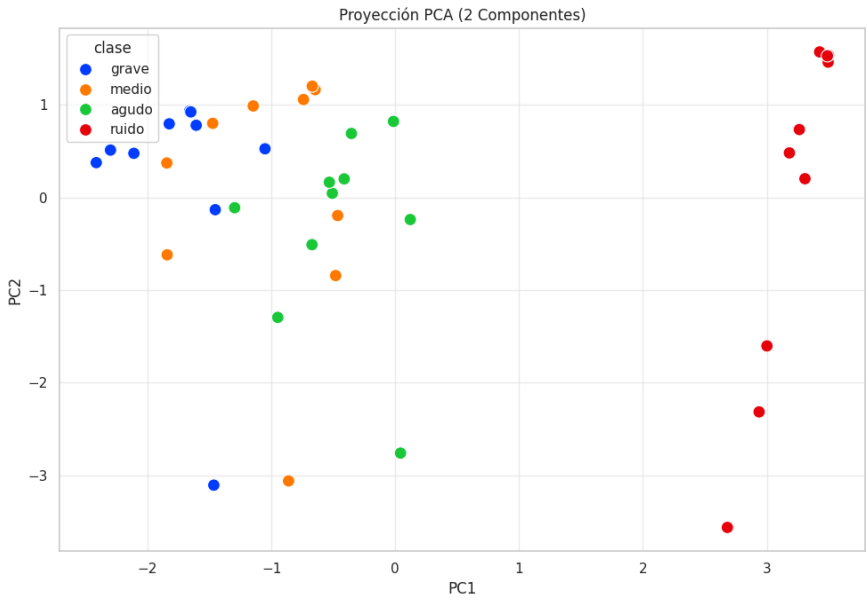

Proyección PCA del dataset

4. Conclusiones y Recomendaciones (3 puntos)

- ¿Es adecuado el dataset para clasificación?
- ¿Qué mejoras propondrías?
- ¿Qué features recomendarías usar para un modelo de ML?

El dataset generado resulta adecuado para tareas de clasificación básicas, ya que permite diferenciar claramente la clase ruido y parcialmente las clases tonales.

Sin embargo, presenta limitaciones propias de su naturaleza sintética, como la baja complejidad de las señales y la ausencia de variabilidad realista.

Mejoras propuestas

- Incorporar features perceptuales como MFCC**.**
- Utilizar datos reales de voz humana.
- Incluir variabilidad en condiciones de grabación (ruido ambiental, reverberación, etc.).

Recomendaciones para modelos de Machine Learning

Para tareas de clasificación, se recomienda priorizar:

- Spectral centroid
- Spectral flatness
- ZCR
- RMS

Además, se sugiere reducir la redundancia entre features mediante análisis de correlación o técnicas como PCA.

Ejercicio 3.2: Reflexión Crítica (5 puntos)

Responder brevemente (máximo 1 carilla):

a) Si tuvieras que explicar a alguien sin conocimientos técnicos qué es el análisis espectral de audio, ¿cómo lo harías? Usá una analogía.

El análisis espectral puede compararse con descomponer un acorde musical en sus notas individuales. Aunque percibimos el sonido como un todo, este análisis permite identificar las frecuencias que lo componen, mostrando qué “componentes” forman ese audio.

b) Durante el TP, ¿qué concepto te resultó más difícil de entender? ¿Cómo lo superaste?

El concepto más complejo fue el PCA, ya que implica reducir múltiples variables a un espacio de menor dimensión sin perder información relevante. Se comprendió mejor al interpretarlo como una forma de proyectar los datos desde el mejor ángulo posible para visualizar sus diferencias.

c) Imaginá que trabajás en una empresa que desarrolla un asistente de voz. Basándote en lo aprendido, ¿qué recomendaciones le darías al equipo de recolección de datos?

Es fundamental recolectar datos en diversas condiciones, incluyendo distintos hablantes, acentos y entornos (ruido, eco, diferentes dispositivos). Esto permite desarrollar modelos más robustos que funcionen correctamente en situaciones reales.

d) ¿Cómo aplicarías estos conocimientos en tu proyecto final o en un contexto laboral real?

Estos conocimientos pueden aplicarse en sistemas de clasificación de audio, detección de fallas en maquinaria o análisis automático de contenido sonoro. La correcta extracción y selección de features es fundamental para cualquier sistema basado en procesamiento de audio.

Anexos / Recursos

[Link al Notebook en Google Colab]

Repositorio GitHub:

Melania Ligorria https://github.com/mel-ligorria/ISPC-Procesamiento-Habla-2026

Miguel Rojas https://github.com/Migueerm/ISPC-Procesamiento-Habla-2026

Ian Marini https://github.com/IanMarini/ISPC-Prosesamiento-Habla-2026

Emilce Robles https://github.com/emirobles/ISPC-Procesamiento-Habla-2026